

INGENIERÍA DE SOFTWARE

METODOLOGÍA DE INVESTIGACIÓN

DOCUMENTO DE INVESTIGACIÓN

DISEÑO DE UN MODELO DE INTELIGENCIA ARTIFICIAL PARA EL ANÁLISIS DE CURRÍCULUMS VITAE BASADO EN CONSISTENCIA DE LA INFORMACIÓN

ESTUDIANTES:

Acosta Medina Aranzazu-23021126

Sarahi Yamileth García Bojórquez-23020009

Cesar Omar Karass Cota-23020143

Alan Zayas Maldonado-23020112

ASESOR:

JESUS JAIME SOLANO NORIEGA

Marzo del 2025, Sin. México



Indice

Planteamiento del problema.....	3-5
Objetivo.....	6
Hipotesis.....	7
Marco Teórico.....	8
Referencias.....	8

Contextualización:

En la actualidad, las organizaciones enfrentan un incremento significativo en el volumen de candidatos durante los procesos de reclutamiento, lo que ha impulsado la adopción de tecnologías basadas en inteligencia artificial (IA) para optimizar la evaluación de currículums vitae (CV). Diversos estudios indican que entre el 65% y el 86% de los reclutadores ya utilizan herramientas de IA en procesos de contratación, destacando su impacto en la automatización y eficiencia del filtrado de candidatos (Businessolution, 2024).

Asimismo, el uso de sistemas de seguimiento de candidatos (en inglés, Applicant Tracking System - ATS) se ha consolidado como estándar en grandes empresas, con niveles de adopción cercanos al 70%, lo que evidencia la creciente digitalización de los procesos de selección (CYL Digital, 2023).

En este contexto, el enfoque tradicional de filtrado basado en palabras clave ha evolucionado hacia modelos de evaluación por competencias, los cuales priorizan la identificación de habilidades, comportamientos y evidencias de desempeño dentro del CV. Este enfoque establece que las competencias deben demostrarse mediante evidencia concreta y no únicamente declararse (Serna Jaramillo, 2025).

Paralelamente, el desarrollo de modelos de lenguaje de gran escala (LLM) ha permitido avances significativos en el análisis semántico del texto. Estos modelos son capaces de interpretar información contextual compleja, identificar patrones lingüísticos y generar evaluaciones automatizadas más profundas que los sistemas tradicionales (Gómez Otero, 2025).

Descripción del Problema:

A pesar de los avances en la aplicación de IA en procesos de selección, persisten desafíos importantes relacionados con la confiabilidad, objetividad y ética de estos sistemas. Investigaciones recientes han demostrado que los modelos automatizados pueden presentar sesgos algorítmicos derivados de los datos de entrenamiento o de su configuración, lo que puede afectar negativamente la equidad en la evaluación de candidatos (Serna Jaramillo, 2025).

Un caso emblemático es el sistema de reclutamiento desarrollado por Amazon en 2017, el cual fue descontinuado tras evidenciar sesgos de género en la selección de candidatos (Dastin, 2018). Este tipo de situaciones resalta la necesidad de desarrollar sistemas de IA responsables, alineados con principios de equidad y transparencia.

Adicionalmente, se ha identificado que los sistemas de inteligencia artificial pueden presentar una mayor consistencia en la evaluación en comparación con los evaluadores humanos, debido a la aplicación uniforme de criterios. Sin embargo, también pueden introducir sesgos sistemáticos, como la sobrevaloración de ciertos patrones lingüísticos o la asociación entre calidad de redacción y competencia profesional del candidato, lo cual puede derivar en evaluaciones inexactas, especialmente en casos de trayectorias laborales no lineales o con interrupciones (Raghavan et al., 2020).

Asimismo, otro problema relevante radica en la capacidad limitada de los modelos de IA para interpretar la veracidad de la información contenida en los CV. Si bien estos sistemas pueden analizar la coherencia y consistencia textual, no cuentan con mecanismos directos para verificar la autenticidad factual de los datos, lo que limita su capacidad para detectar información falsa o engañosa.

Diversas investigaciones han analizado el uso de inteligencia artificial en procesos de selección de personal, destacando su capacidad para mejorar la eficiencia y consistencia en la evaluación de candidatos. En particular, el estudio de Serna Jaramillo (2025) desarrolló un analizador de CV basado en competencias, en el cual se comparó la evaluación realizada por expertos humanos frente a un sistema automatizado de IA. Los resultados evidenciaron que la IA presenta una mayor consistencia en la aplicación de criterios evaluativos, aunque con una ligera tendencia a otorgar puntuaciones superiores en competencias como orientación a resultados y adaptación al cambio (Serna Jaramillo, 2025).

Por otra parte, estudios relacionados con el procesamiento automático de currículums vitae han demostrado que es posible desarrollar sistemas capaces de extraer, clasificar y estructurar información de candidatos mediante la integración de distintas tecnologías. El reconocimiento óptico de caracteres (OCR) permite convertir documentos en formato imagen o PDF en texto digital, mientras que las técnicas de procesamiento de lenguaje natural (NLP) y los modelos de lenguaje permiten analizar, interpretar y estructurar dicha información (Gómez Otero, 2025).

Brecha de conocimiento

A pesar de la creciente implementación de sistemas de IA en el ámbito de recursos humanos, existe una limitada evidencia sobre el diseño de modelos estructurados que permitan evaluar la consistencia de la información contenida en currículums vitae mediante inteligencia artificial. En particular, no se dispone de suficientes estudios que propongan modelos que integren la extracción de entidades (NER), reglas de consistencia temporal y verificación externa para la detección automatizada de inconsistencias.

Asimismo, aunque existen investigaciones que analizan la diferencia entre evaluación humana y automatizada, aún es necesario profundizar en la validación de modelos específicos y su comportamiento en contextos controlados (Serna Jaramillo, 2025).

Pregunta de Investigación:

¿Cómo diseñar un modelo basado en inteligencia artificial que permita analizar currículums vitae y estimar la consistencia de la información contenida en ellos mediante una validación en un entorno controlado?

Justificación

Desde el punto de vista teórico, esta investigación contribuye al análisis del uso de modelos de lenguaje en el ámbito de la evaluación por competencias, ampliando el conocimiento sobre su funcionamiento, capacidades y limitaciones en contextos reales. En el ámbito práctico, los resultados pueden servir como referencia para organizaciones que buscan implementar herramientas de IA en sus procesos de selección, permitiéndoles mejorar la eficiencia operativa. Se ha demostrado que el uso de IA puede reducir tiempos de contratación y optimizar la toma de decisiones en recursos humanos ([Jamy.ai](#), 2024).

Desde una perspectiva ética, el estudio aporta elementos para el desarrollo de sistemas de IA responsables, alineados con principios de equidad, transparencia y supervisión humana (Serna Jaramillo, 2025).

Asimismo, esta investigación contempla la validación conceptual del modelo propuesto mediante pruebas en un entorno controlado, sin considerar su implementación en un sistema productivo.

Objetivo general

Proponer un modelo basado en inteligencia artificial para el análisis de currículums vitae que permita estimar la consistencia de la información contenida en ellos, y validarlo mediante pruebas en un entorno controlado.

Objetivos específicos

1. Analizar el funcionamiento de los modelos de inteligencia artificial aplicados al procesamiento y evaluación de currículums vitae, considerando sus características, alcances y limitaciones.
2. Diseñar un modelo de evaluación basado en inteligencia artificial capaz de generar un puntaje de consistencia de la información contenida en un CV en una escala de 0 a 1.
3. Proponer la estructura de un sistema basado en inteligencia artificial para el análisis automatizado de currículums vitae.

Hipótesis general

Es posible diseñar un modelo basado en inteligencia artificial que permita analizar currículums vitae y estimar la consistencia de la información contenida en ellos mediante una validación en un entorno controlado.

Hipótesis específicas

H1. Los modelos de inteligencia artificial basados en procesamiento de lenguaje natural permiten analizar la coherencia textual en currículums vitae.

H2. Es posible establecer criterios de evaluación que permitan medir la consistencia de la información contenida en un currículum vitae.

H3. Un modelo de inteligencia artificial puede generar un puntaje cuantitativo que represente el nivel de consistencia de la información analizada.

H4. La aplicación de un modelo de inteligencia artificial en un entorno controlado permite validar su capacidad para identificar inconsistencias en la información contenida en currículums vitae.

Hipótesis Nula

No es posible diseñar un modelo basado en inteligencia artificial que permita analizar currículums vitae y estimar la consistencia de la información contenida en ellos.

Introducción al Marco Teórico

El presente marco teórico tiene como propósito fundamental proporcionar los fundamentos conceptuales, empíricos y metodológicos que sustentan la propuesta de investigación: el diseño de un modelo basado en inteligencia artificial (IA) para analizar currículums vitae (CV) mediante la estimación de la consistencia de su información.

Para ello, se integran y articulan tres cuerpos de literatura:

- (a) La psicología organizacional y la medición del fraude en CVs (resume fraud), que permite comprender las dimensiones del problema.
- (b) El procesamiento de lenguaje natural (NLP) y el aprendizaje automático aplicados a la detección de inconsistencias, que proporcionan las herramientas tecnológicas.
- (c) Los principios de inteligencia artificial responsable y evaluación de sesgos, que garantizan el desarrollo ético y confiable del modelo.

Esta integración permite construir una base sólida que vincula la definición del problema (¿qué es el fraude en CVs?), las herramientas para abordarlo (¿cómo puede la IA detectarlo?), y las consideraciones éticas para hacerlo de manera confiable (¿cómo garantizar que el modelo sea justo y explicable?).

El marco se organiza en seis apartados principales:

1. Definición y dimensiones del fraude en CVs
2. El papel de la IA y el NLP en la evaluación automatizada de CVs
3. La consistencia de la información como constructo central
4. Técnicas y modelos específicos para la detección de inconsistencias
5. Consideraciones sobre sesgo algorítmico e IA responsable
6. Síntesis y relación con las hipótesis de investigación

Definición y Dimensiones del Fraude en el Currículum Vitae

1.1 Definición conceptual

El punto de partida de cualquier investigación sobre inconsistencia intencional en CVs es la definición precisa del fenómeno. Henle, Dineen y Duffy (2019), en su estudio fundamental para el desarrollo y validación de una medida de fraude en CVs, definen el resume fraud como:

"La tergiversación intencional de información en un currículum con el fin de presentarse de manera más favorable de lo que es real, diseñada para engañar a los reclutadores, crear ventajas personales en los procesos de contratación, obtener entrevistas y eventualmente asegurar ofertas de trabajo."

Esta definición enfatiza tres elementos cruciales: (a) la intencionalidad (excluye errores u omisiones no deliberadas), (b) la direccionalidad positiva (presentarse como mejor candidato de lo que realmente se es), y (c) el contexto de selección (el engaño ocurre dentro de un proceso competitivo de contratación).

1.2 Dimensiones del fraude en CVs

Para operacionalizar el constructo y permitir su estudio sistemático, Henle et al. (2019) proponen una estructura tridimensional validada empíricamente mediante análisis factorial exploratorio y confirmatorio en múltiples muestras (estudiantes universitarios y trabajadores en activo).

Dimensión	Definición	Ejemplos típicos
Fabricación	Inventar o falsificar información completamente. Incluir datos que nunca fueron verdaderos.	Listar títulos universitarios no obtenidos, inventar empleos que nunca existieron, crear logros ficticios, falsificar fechas de graduación.
Embellecimiento	Exagerar información que es parcialmente cierta. "Estirar la verdad" para que parezca más impresionante.	Inflar la importancia de un cargo, exagerar el nivel de responsabilidad, sobredimensionar la participación en proyectos exitosos.
Omisión	Excluir intencionalmente información relevante y negativa. Ocultar datos que podrían perjudicar la candidatura.	No mencionar un despido por mala conducta, omitir períodos prolongados de desempleo, excluir empleos de corta duración.

1.3 Prevalencia y consecuencias del fraude en CVs

Henle et al. (2019, p. 95) reportan cifras consistentes a través de sus estudios: en promedio, el **72%** de los solicitantes admite haber incurrido en algún tipo de embellecimiento, el **61%** en omisión, y el **31%** en fabricación. Estas cifras, obtenidas mediante auto-reporte anónimo, sugieren que el fraude en CVs es más una norma que una excepción en los procesos de selección.



Las consecuencias organizacionales son significativas: menor desempeño laboral (los candidatos carecen de las competencias que afirmaron tener), mayor desviación en el trabajo (el comportamiento engañoso se extiende más allá del proceso de selección), daño a la reputación, aumento de costos de rotación y capacitación, y riesgos legales por contratación negligente (Henle et al., 2019; Amsalakshmi et al., 2025).

El Papel de la Inteligencia Artificial y el NLP en la Evaluación Automatizada de CVs

2.1 Limitaciones de los enfoques tradicionales

Henle et al. (2019) identifican tres limitaciones principales de los métodos objetivos de verificación (como servicios de verificación de antecedentes):

1. Cobertura limitada: Solo verifican la información seleccionada explícitamente, dejando sin detectar otras falsificaciones.
2. Dificultad para verificar ciertos datos: Aspectos como el "nivel de participación en un proyecto" son subjetivos y difíciles de corroborar externamente.
3. Incapacidad para evaluar intencionalidad: No distinguen entre errores honestos y engaños deliberados.

Por otro lado, la verificación manual por parte de reclutadores es costosa, lenta, inconsistente y propensa a sesgos humanos.

2.2 La promesa de la automatización con IA

Frente a estas limitaciones, Amsalakshmi et al. (2025) proponen un sistema automatizado de detección de fraude en CVs que integra tres capacidades clave:

1. Procesamiento de lenguaje natural (NLP): Para extraer información estructurada del texto no estructurado del CV.
2. Verificación cruzada automatizada: Para contrastar las afirmaciones del candidato con fuentes externas (APIs, bases de datos) y reglas de consistencia interna.
3. Modelos de aprendizaje automático: Para clasificar CVs como fraudulentos o genuinos basándose en patrones aprendidos de datos etiquetados.

La Consistencia de la Información como Constructo Central

3.1 Definición multidimensional de la consistencia

Un aporte central de esta investigación es la conceptualización de la consistencia de la información en un CV no como una propiedad binaria (consistente/inconsistente), sino como un constructo multidimensional y graduable que puede cuantificarse mediante un puntaje continuo (por ejemplo, de 0 a 1).

Aclaración conceptual: Es importante distinguir entre fraude intencional (constructo psicológico estudiado por Henle et al., 2019) e inconsistencia informativa (constructo documental observable). El presente modelo se enfoca en este último, reconociendo que la inconsistencia puede ser indicio de fraude, pero también puede derivarse de errores no intencionales o mala redacción. Esta distinción será considerada en la interpretación de los resultados.

A partir de la literatura revisada, se identifican tres dimensiones de la consistencia:

Dimensión	Definición	Indicadores de inconsistencia
Consistencia semántica y lingüística	Coherencia interna del discurso, plausibilidad de las afirmaciones, ausencia de patrones lingüísticos anómalos.	Descripciones vagas o genéricas, jerga excesiva, falta de especificidad en logros, narrativas contradictorias.
Consistencia factual y temporal	Coherencia lógica de los datos factuales (fechas, cargos, transiciones laborales).	Superposición de empleos, saltos temporales inexplicables, progresiones profesionales improbables, títulos inconsistentes con funciones.
Consistencia externa (verificabilidad)	Correspondencia entre las afirmaciones del CV y fuentes externas de información confiables.	Instituciones educativas inexistentes, cargos no verificables en redes profesionales, períodos laborales sin

3.2 Relación entre consistencia y dimensiones del fraude

La siguiente tabla articula cómo las dimensiones del fraude propuestas por Henle et al. (2019) se manifiestan como problemas de consistencia:

Dimensión del fraude	Dimensión de consistencia afectada	Manifestación en el CV
Fabricación	Consistencia externa (y secundariamente factual)	Una institución educativa o un empleador no existen en bases de datos externas.
Embellecimiento	Consistencia semántica y factual	Descripción desproporcionada respecto al cargo; logros improbables para el nivel del puesto.
Omisión	Consistencia factual (temporal)	Brechas temporales no explicadas que ocultan períodos de desempleo o empleos no deseados.

3.3 Hacia una cuantificación de la consistencia

Un aspecto fundamental para la automatización del análisis de CVs es la necesidad de traducir las evaluaciones cualitativas (ej., "este CV parece inconsistente") en una medida cuantitativa estandarizada que pueda ser interpretada por los reclutadores y utilizada por sistemas de selección (Amsalakshmi et al., 2025). Diversos sistemas de detección de fraude documentados en la literatura (Gupta et al., 2023; Khan & Zhou, 2024) emplean lo que denominan un puntaje de riesgo o de credibilidad, generalmente en un rango de 0 a 1, donde valores cercanos a 1 indican alta veracidad/consistencia y valores cercanos a 0 indican alta probabilidad de fraude. La construcción de dicho puntaje puede basarse en la agregación de múltiples señales de inconsistencia detectadas por el modelo. Siguiendo la taxonomía de Henle et al. (2019), estas señales se agrupan en tres categorías:

Categoría de señales	Relación con el fraude	Ejemplo de señal detectable por IA
Anomalías semánticas y lingüísticas	Asociada a fabricación y embellecimiento	Descripciones vagas, patrones de exageración, desalineación semántica entre cargo y logros declarados.
Inconsistencias factuales y temporales	Asociada a fabricación y omisión	Superposición o saltos inexplicables en fechas de empleo, progresiones profesionales improbables.
Fallas en verificación externa	Asociada a fabricación	Institución educativa no acreditada, empleador sin presencia verificable en bases de datos externas.

Técnicas y Modelos Específicos para la Detección de Inconsistencias

4.1 Extracción de información mediante NLP

El primer paso técnico para cualquier sistema automatizado de análisis de CVs es convertir el texto no estructurado en datos estructurados. Amsalakshmi et al. (2025) documentan el uso de las siguientes técnicas:

- Tokenización y limpieza textual: Eliminación de ruido (caracteres especiales, formato inconsistente), eliminación de stop words, lematización (reducción de palabras a su forma base).
- Reconocimiento de Entidades Nombradas (NER): Identificación y clasificación de entidades clave como nombres de instituciones educativas, cargos, fechas, habilidades técnicas y nombres de empresas. Modelos como spaCy o versiones fine-tuned de BERT han demostrado alta efectividad en esta tarea.
- Extracción de relaciones: Identificación de vínculos semánticos entre entidades (ej., "Juan Pérez" → "trabajó en" → "Google" → "como" → "Ingeniero de Software").

4.2 Modelos de aprendizaje automático para clasificación de fraude

La literatura reporta múltiples enfoques para la clasificación de CVs como fraudulentos o genuinos:

Modelo	Características	Rendimiento reportado	Fuente
Random Forest	Clasificador basado en ensamblaje de árboles de decisión; maneja bien datos tabulares extraídos del CV.	89% de precisión en detección de inconsistencias temporales	Sharma et al. (2023)
BERT (<i>fine-tuned</i>)	Modelo transformer pre-entrenado que captura contexto bidireccional; excelente para detectar sutilezas semánticas.	92% de F1-score en detección de fraudes	Gupta et al. (2023)
BiLSTM con atención	Red neuronal recurrente bidireccional con mecanismos de atención para enfocarse en partes relevantes del texto.	Alta capacidad para capturar irregularidades lingüísticas	Khan & Zhou (2024)
Fraud-BERT	Versión de BERT adaptada al dominio de reclutamiento (<i>fine-tuning</i> con datos de CVs reales y fraudulentos).	Superior a BERT base en detección de fraudes adversariales	Amsalakshmi et al. (2025)

4.3 Verificación externa y APIs

La tercera pata del enfoque de Amsalakshmi et al. (2025) es la verificación cruzada con fuentes externas. Aunque el acceso completo a APIs como LinkedIn puede tener restricciones de costo y privacidad, se pueden implementar verificaciones más simples:

- Verificación de instituciones educativas: Consulta a bases de datos públicas de universidades acreditadas (ej., CHEA, bases de datos gubernamentales).
- Verificación de dominios de correo corporativo: Validar que el dominio del correo electrónico proporcionado por el candidato corresponda con el empleador listado.
- Verificación de presencia en redes profesionales: Búsqueda automatizada (respetando límites de tasa y términos de servicio) de perfiles que coincidan con el nombre, cargo y empleador declarados.

Consideraciones sobre Sesgo Algorítmico e IA Responsable

5.1 El problema del sesgo en sistemas de IA para reclutamiento

Un aspecto crítico que no puede omitirse en un marco teórico riguroso es la discusión sobre los sesgos algorítmicos. El caso más emblemático es el de Amazon (2018), cuyo sistema de reclutamiento basado en IA fue descontinuado porque penalizaba sistemáticamente los CVs que contenían la palabra "mujer" o que provenían de universidades con alta matrícula femenina. El sistema había aprendido estos sesgos de los datos de entrenamiento, que reflejaban una fuerza laboral históricamente dominada por hombres (Dastin, 2018).

Raghavan et al. (2020) identifican tres fuentes principales de sesgo en sistemas de contratación algorítmica:

Fuente de sesgo	Descripción	Ejemplo en análisis de CVs
Sesgo en los datos de entrenamiento	Los datos históricos reflejan discriminación pasada o sobrerrepresentan ciertos grupos.	CVs de candidatos contratados exitosamente provienen mayoritariamente de un género o grupo étnico.
Sesgo en la representación de características	Las variables utilizadas por el modelo correlacionan con atributos protegidos.	La "consistencia de trayectoria laboral" puede penalizar interrupciones por maternidad o licencias médicas.
Sesgo en la evaluación (label bias)	Las etiquetas de "CV exitoso" reflejan juicios humanos sesgados.	Reclutadores humanos etiquetaron CVs como "buenos" basándose en criterios implícitamente sesgados.

5.2 Inteligencia Artificial Explicable (XAI) como requisito

Para mitigar estos riesgos y generar confianza en el sistema, la literatura recomienda incorporar principios de Inteligencia Artificial Explicable (XAI) (Amsalakshmi et al., 2025; Das & Roy, 2022). Esto significa que el modelo no solo debe producir un puntaje de consistencia, sino también identificar qué partes del CV contribuyeron más a ese puntaje.

Las principales herramientas XAI documentadas son:

- SHAP (SHapley Additive exPlanations): Asigna a cada característica de entrada una "importancia" basada en teoría de juegos cooperativos, permitiendo identificar qué palabras, frases o entidades influyeron más en la clasificación.
- LIME (Local Interpretable Model-agnostic Explanations): Aproxima el modelo localmente con un modelo interpretable (ej., regresión lineal), generando explicaciones específicas como: "Este CV fue marcado como inconsistente porque la fecha de graduación (2015) no coincide con el período de empleo declarado (2014-2016)".
- Visualización de atención (para transformers): Muestra qué partes del texto el modelo "prestó más atención" al hacer una predicción, resaltando en el CV original las secciones consideradas sospechosas.

5.3 Evaluación de sesgos en el entorno controlado

Como parte del diseño de esta investigación, se propone evaluar el modelo con subconjuntos de datos contruidos específicamente para detectar:

- Sesgo de género: ¿El sistema asigna sistemáticamente puntajes de consistencia más bajos a CVs con nombres o pronombres femeninos, manteniendo constante el contenido?
- Sesgo por trayectorias no lineales: ¿El sistema penaliza desproporcionadamente CVs con interrupciones laborales (potencialmente asociadas a maternidad, enfermedad o cuidado de familiares)?
- Sesgo lingüístico: ¿El sistema asocia ciertos estilos de redacción (ej., "lideré un equipo" vs. "apoyé al equipo") con mayor consistencia, incluso cuando el contenido fáctico es equivalente?

Síntesis y Relación con las Hipótesis de Investigación

6.1 Integración conceptual

El marco teórico desarrollado permite articular los tres componentes de la investigación:

Fraude en CVs (Henle et al.) → Dimensiones analizables

(Fabricación/Embelllecimiento/Omisión) → Técnicas de IA/NLP (Amsalakshmi et al.)

→ Puntaje de consistencia (propuesta central) + XAI (IA responsable)

6.2 Correspondencia con las hipótesis

Hipótesis	Fundamentación en el marco teórico
H1: Los modelos de IA basados en NLP permiten analizar la coherencia textual en CVs.	Respaldada por la evidencia de Amsalakshmi et al. (2025) y la literatura sobre BERT y NLP aplicado a detección de fraudes (sección 4).
H2: Es posible establecer criterios de evaluación para medir la consistencia de la información en un CV.	Respaldada por la taxonomía de Henle et al. (2019) y la propuesta de consistencia multidimensional (sección 3).
H3: Un modelo de IA puede generar un puntaje cuantitativo que represente el nivel de consistencia.	Respaldada por los sistemas de <i>scoring</i> reportados en la literatura (sección 4.2) y la justificación conceptual de cuantificación (sección 3.3).
H4: La aplicación del modelo en un entorno controlado permite validar su capacidad para identificar inconsistencias.	Respaldada por la necesidad de evaluar precisión, recall y, críticamente, sesgos algorítmicos (sección 5).
Hipótesis nula: No es posible diseñar tal modelo.	Sería refutada si el modelo no supera umbrales mínimos de precisión (ej., >80%) o si muestra sesgos sistemáticos inaceptables.

6.3 Aportes esperados del estudio


Con base en este marco teórico, se espera que la investigación realice las siguientes contribuciones:

1. Aporte teórico: Ampliar el entendimiento sobre cómo las dimensiones del fraude (fabricación, embellecimiento, omisión) pueden ser operacionalizadas computacionalmente mediante métricas de consistencia.
2. Aporte metodológico: Proporcionar un procedimiento validado en entorno controlado para evaluar modelos de IA en análisis de CVs, incluyendo pruebas explícitas de sesgo.
3. Aporte práctico: Ofrecer a las organizaciones una herramienta conceptual y técnica para priorizar la revisión de CVs con baja consistencia, reduciendo tiempos y mejorando la calidad de las contrataciones.

Conclusión del Marco Teórico

La integración de la literatura sobre fraude en CVs (Henle et al., 2019), técnicas de IA/NLP (Amsalakshmi et al., 2025) y principios de IA responsable (Raghavan et al., 2020; Das & Roy, 2022) proporciona una base sólida y coherente para el diseño, implementación y validación del modelo propuesto.

Este marco no solo fundamenta las hipótesis de investigación, sino que también establece los criterios de éxito (precisión, explicabilidad, ausencia de sesgos inaceptables) y las limitaciones que deben considerarse al interpretar los resultados. La distinción entre fraude intencional e inconsistencia informativa observable queda claramente establecida, alineando el constructo medido por el modelo con su capacidad real de detección.



Diseño Metodológico

El presente estudio se enmarca dentro de un enfoque de investigación aplicada con un componente de desarrollo tecnológico. El propósito es diseñar y validar conceptualmente un modelo basado en inteligencia artificial, no construir un sistema productivo completo.


3.1 Tipo de investigación

Característica	Descripción
Enfoque	Mixto (cualitativo para el diseño del modelo; cuantitativo para la validación)
Alcance	Descriptivo y propositivo
Método	Validación en entorno controlado con datos sintéticos y reales anonimizados
Temporalidad	Transversal (el modelo se prueba con un conjunto fijo de CVs)

3.2 Fases de la investigación

La investigación se organiza en cuatro fases:

Fase	Actividad principal	Entregable
Fase 1	Revisión sistemática de literatura y definición de requisitos	Marco teórico y lista de requisitos del modelo
Fase 2	Diseño arquitectónico del modelo	Diagrama de componentes y descripción de módulos
Fase 3	Implementación de prototipo conceptual (entorno controlado)	Prototipo funcional en Python (NLP + reglas + scoring)
Fase 4	Validación y evaluación de resultados	Métricas de precisión, recall, y análisis de sesgos



3.3 Técnicas e instrumentos

Técnica	Aplicación	Herramienta sugerida
Análisis documental	Extracción de requisitos del marco teórico	Matriz de análisis
Diseño de software	Definición de arquitectura y módulos	Diagramas UML (componentes, secuencia)
Procesamiento de NLP	Extracción de entidades y análisis semántico	Python + spaCy / BERT
Verificación externa	Consulta simulada a bases de datos	Archivos JSON con datos de prueba
Evaluación del modelo	Cálculo de métricas de desempeño	Scikit-learn (precision, recall, F1)

3.4 Población y muestra de validación

Para la validación conceptual en entorno controlado:

- Conjunto de datos: Se utilizará un corpus mixto de 200 CVs:
 - 100 CVs reales anonimizados (fuentes: repositorios públicos como Kaggle "Resume Dataset")
 - 100 CVs sintéticos con inconsistencias controladas (generados por el equipo)
- Criterios de inclusión:
 - CVs en formato texto o PDF
 - Información estructurada (educación, experiencia, habilidades)
 - Fechas presentes para validación temporal
- Distribución esperada:

Tipo de CV	Cantidad	Propósito
Consistentes (control)	80	Evaluar falsos positivos
Con fabricaciones	40	Evaluar detección de invenciones
Con embellecimientos	40	Evaluar detección de exageraciones
Con omisiones	40	Evaluar detección de brechas ocultas

3.5 Validez y confiabilidad del estudio


Criterio	Estrategia de mitigación
Validez interna	Uso de entorno controlado con CVs etiquetados previamente por expertos
Validez externa	Inclusión de CVs de diferentes industrias y niveles de antigüedad
Confiabilidad	Ejecución del modelo múltiples veces (k-fold validation) con mismos datos
Sesgo algorítmico	Pruebas específicas con subconjuntos por género y trayectorias no lineales

Propuesta del Modelo

Propuesta del Modelo de IA para Análisis de Consistencia

Basado en el marco teórico (Henle et al., 2019; Amsalakshmi et al., 2025) y en la taxonomía de tres dimensiones de fraude (fabricación, embellecimiento, omisión), se propone un modelo de inteligencia artificial estructurado en **cuatro capas**.

4.1 Arquitectura general del modelo



4.2 Descripción de los submódulos

4.2.1 Submódulo de consistencia semántica (Csem)

- Técnica: Modelo BERT fine-tuned con corpus de CVs
- Función: Detectar patrones lingüísticos anómalos (exageraciones, descripciones vagas, inconsistencia entre cargo y logros)
- Salida: Puntaje de 0 a 1 (1 = semánticamente consistente)

4.2.2 Submódulo de consistencia factual y temporal (Cfact)

- Técnica: Reglas heurísticas + validación cruzada de fechas
- Funciones específicas:
 - Detectar superposición de fechas entre empleos
 - Detectar brechas temporales no explicadas (>6 meses sin actividad)
 - Validar progresión profesional (ej. no pasar de becario a director en 1 año)
- Salida: Puntaje de 0 a 1 (1 = factualmente consistente)

4.2.3 Submódulo de verificación externa (Cext)

- Técnica: Consulta simulada o real a APIs externas
- Fuentes de verificación propuestas:
 - Base de datos de universidades acreditadas
 - Base de datos de empresas (dominios de correo)
 - Perfiles públicos (simulado en fase conceptual)
- Salida: Puntaje de 0 a 1 (1 = verificable externamente)

4.3 Cálculo del puntaje de consistencia

Para la fase de validación conceptual, se propone un promedio simple de los tres submódulos:

$$C_{total} = (C_{sem} + C_{fact} + C_{ext}) / 3$$

Donde:

- Ctotal = Puntaje general de consistencia (escala 0-1)
- Csem = Consistencia semántica (salida de BERT)
- Cfact = Consistencia factual/temporal (porcentaje de reglas cumplidas)
- Cext = Verificabilidad externa (porcentaje de ítems verificados)

Interpretación:

Rango	Nivel de consistencia	Acción sugerida para reclutador
0.80 – 1.00	Alta	Proceder con entrevista
0.60 – 0.79	Media	Revisión adicional manual
0.40 – 0.59	Baja	Verificación rigurosa de antecedentes
0.00 – 0.39	Muy baja	Descartar o verificación exhaustiva

4.4 Módulo de explicabilidad (XAI)

Siguiendo los principios de IA responsable (sección 5 del marco teórico), el modelo incluirá:

- SHAP: Para identificar qué entidades (ej. "Universidad X", "fecha 2015") contribuyeron más al puntaje.
- Salida textual: Generación automática de explicaciones como:
- "El CV obtuvo un puntaje bajo (0.35) debido a: (1) brecha no explicada de 18 meses entre empleos, (2) institución educativa no encontrada en bases de datos acreditadas."

4.5 Tecnologías sugeridas para implementación

Componente	Tecnología sugerida	Justificación
Extracción de texto	PyPDF2 / pdfplumber	Gratuito, compatible con PDFs
NLP y NER	spaCy (modelo es_core_news_lg)	Buen rendimiento en español
Análisis semántico	BERT multilingüe fine-tuned	Captura contexto, 92% F1 reportado
Clasificación (opcional)	Random Forest de scikit-learn	Complementa para datos tabulares
Explicabilidad	SHAP (Python library)	Estándar en XAI
Validación	Jupyter Notebook / Google Colab	Fácil prototipado y pruebas

Resultado Esperado

Con la implementación del modelo propuesto, se espera obtener:

Resultado	Métrica esperada	Criterio de éxito
Precisión en detección de fabricaciones	>85%	Basado en literatura (Gupta et al., 2023)
Precisión en detección de omisiones	>75%	Las omisiones son más difíciles de detectar
Baja tasa de falsos positivos	<15%	Evitar descartar CVs válidos
Explicabilidad aceptable	>80% de aceptación	Evaluated por usuarios simulados
Sin sesgos significativos	Diferencia <5% entre grupos	Evaluated en subconjuntos de prueba

Referencias

- Amsalakshmi, M., Kamate, K. V., Kumar, M., & Abhas. (2025). AI Powered Resume Fraud Detection. International Research Journal of Computer Science, 12(11), 678-682.
- Businessolution. (2024). AI in recruitment statistics. <https://businessolution.org/es/ai-in-recruitment-statistics/>
- CYL Digital. (2023). Búsqueda de empleo con inteligencia artificial. <https://www.cyldigital.es/>
- Das, K., & Roy, T. (2022). Explainable AI (XAI) for Resume Analysis. [Referencia en Amsalakshmi et al., 2025].
- Dastin, J. (2018). Amazon scraps secret AI recruiting tool that showed bias against women. Reuters. <https://www.reuters.com/>
- Gómez Otero, A. (2025). Procesado automático de CVs con IA para selección de personal (Trabajo de Fin de Grado).
- Gupta, R., et al. (2023). Deep Learning Fraud Detection. [Referencia en Amsalakshmi et al., 2025].
- Henle, C. A., Dineen, B. R., & Duffy, M. K. (2019). Assessing Intentional Resume Deception: Development and Nomological Network of a Resume Fraud Measure. Journal of Business and Psychology, 34, 87-106.
- Jamy.ai. (2024). Beneficios de usar IA en reclutamiento. <https://www.jamy.ai/>
- Khan, L., & Zhou, H. (2024). Textual Fraud Analysis (Fraud NLP). [Referencia en Amsalakshmi et al., 2025].
- Raghavan, M., Barocas, S., Kleinberg, J., & Levy, K. (2020). Mitigating bias in algorithmic hiring: Evaluating claims and practices. Proceedings of the ACM Conference on Fairness, Accountability, and Transparency. <https://doi.org/10.1145/3351095.3372828>
- Serna Jaramillo, J. (2025). Analizador de CV por competencias: Aplicación de IA responsable en procesos de selección.
- Sharma, A., et al. (2023). Machine Learning Resume Parsing. [Referencia en Amsalakshmi et al., 2025].